Otimização de carteiras

April 12, 2021

Nesse exercício iremos, primeiramente, analisar a correlação das ações do índice bovespa exatamente com o índice. O intuito é criar uma carteira usando as 5 ações com maior correlação com o Ibov. Analisaremos o portfólio criado com pesos iguais para cada ação (20%) e depois usaremos a fronteira eficiente de Markowitz para equilibrar os pesos de cada ação de forma a aumentar a eficiência com volatilidade mínima além de também analisar a carteira com risco ideal

1 Importando os pacotes

[1]:
```
import yfinance as yf
import pandas as pd
pd.set_option('display.max_rows', 500)
import math
import matplotlib.pyplot as plt
plt.style.use('fivethirtyeight')
%matplotlib inline
import seaborn as sbs
import scipy.stats as stats
import config
import os
from datetime import datetime
import numpy as np
```

2 Baixando os dados históricos das ações

[2]:
```
ibovurl= "http://bvmf.bmfbovespa.com.br/indices/ResumoCarteiraTeorica.aspx?
 ↪Indice=ibov&idioma=pt-br"
ibov = pd.read_html(ibovurl)

# Selecionando apenas a coluna com os Tickers

tickers = ibov[0][0:]['Código'].tolist()
tickers.remove('Quantidade Teórica Total  Redutor')

# Adicionando .SA em todas as ações

for i in range(0, len(tickers)):
```

```
    tickers[i] = tickers[i] + '.SA'



# Buscando no yahoo finance o preço de fechamento ajustado.

dataset = yf.download(tickers=tickers, start='2015-01-01')['Adj Close']
```

```
[**********100%**********]  82 of 82 completed
```

3 Removendo os NA's

Para melhorar a nossa análise, vamos remover as ações que possuírem mais de 25% de dados como "NA's"

[3]:
```
missing_fractions = dataset.isnull().mean().sort_values(ascending=False)

missing_fractions.head(10)

drop_list = sorted(list(missing_fractions[missing_fractions > 0.25].index))

dataset.drop(labels=drop_list, axis=1, inplace=True)
dataset.shape
```

[3]:
```
(1558, 73)
```

4 Retonos diários e acumulados

[4]:
```
retorno = dataset.pct_change()
retorno_acumulado = (1 + retorno).cumprod()
retorno_acumulado.iloc[0] = 1
retorno_acumulado = pd.DataFrame(retorno_acumulado)
```

5 Baixando dados históricos do IBOV

Para comparação, vamos usar o ETF BOVA11.

[5]:
```
ibov = yf.download('BOVA11.SA', start = '2015-01-01')["Adj Close"]
IBOV = ibov / ibov.iloc[0]
```

```
[**********100%**********]  1 of 1 completed
```

6 Adicionando a série do IBOV ao dataframe de retornos acumulados

[6]:
```
retorno_acumulado = retorno_acumulado.assign(IBOV = IBOV)
```

7 Correlação das ações do IBOV com o IBOV

[37]:
```
correlacao = retorno_acumulado.corr()
correlacao = pd.DataFrame(correlacao)
corr_stocks_ibov = correlacao['IBOV'].sort_values(ascending = False)
corr_stocks_ibov = pd.DataFrame(corr_stocks_ibov)
corr_stocks_ibov[1:6]
```

[37]:

	IBOV
PETR4.SA	0.960602
ENGI11.SA	0.959459
LREN3.SA	0.951459
ITSA4.SA	0.950491
EQTL3.SA	0.939640

8 Analisando o portfólio com pesos iguais (20%)

[8]:
```
assets = ['PETR4.SA','ENGI11.SA','LREN3.SA','ITSA4.SA','EQTL3.SA']
pesos = np.array([0.2,0.2,0.2,0.2,0.2])
```

[9]:
```
dataset = yf.download(tickers=assets, start='2015-04-02')['Adj Close']
dataset = pd.DataFrame(dataset)
```

```
[**********100%**********]  5 of 5 completed
```

[10]:
```
# Retornos diários

returns = dataset.pct_change()

# Retornos anuais
ind_er = dataset.resample('Y').last().pct_change().mean()
```

[11]:
```
# matrix de covariancia anualizada

cov_matrix_annual = returns.cov()*252
```

[12]:
```
# Calculando a Variância do Portfólio

port_variance = np.dot(pesos.T,np.dot(cov_matrix_annual, pesos))
print('A variância do portfólio é de', port_variance)
```

```
A variância do portfólio é de 0.08102249422691957
```

[13]:
```
# Calculando a volatilidade do Portfólio

port_volatility = np.sqrt(port_variance)
print('A volatilidade do portfólio é de', port_volatility)
```

```
A volatilidade do portfólio é de 0.2846445050003944
```

[14]:
```
# Calculando o retorno anual do portfólio

portfolio_annual_return = np.sum(returns.mean() * pesos) * 252
print('O retorno anual desse portfólio é de', portfolio_annual_return)
```

```
O retorno anual desse portfólio é de 0.25828609259447577
```

[15]:
```
# Calculando o retorno anual esperado, volatilidade e a variância

percent_var = str(round(port_variance, 2) * 100)+ '%'
percent_vols = str(round(port_volatility,2) * 100)+ "%"
percent_ret = str(round(portfolio_annual_return, 2) *100) + '%'

print('Retorno anual esperado: ' + percent_ret)
print('Volatilidade anual/ risco: '+ percent_vols)
print('Variância anual: '+ percent_var)
```

```
Retorno anual esperado: 26.0%
Volatilidade anual/ risco: 28.000000000000004%
Variância anual: 8.0%
```

9 Analisando o Portfólio de acordo com a EFM

[16]:
```
assets = ['PETR4.SA','ENGI11.SA','LREN3.SA','ITSA4.SA','EQTL3.SA']

df = yf.download(tickers=assets, start='2015-04-02')['Adj Close']
df = pd.DataFrame(df)
```

```
[**********100%**********]  5 of 5 completed
```

[17]:
```
p_ret = []
p_vol = []
p_weights = []

num_assets = len(df.columns)
num_portfolios = 50000

cov_matrix = df.pct_change().apply(lambda x: np.log(1+x)).cov()
```

[18]:
```
for portfolio in range(num_portfolios):
    weights = np.random.random(num_assets)
    weights = weights/np.sum(weights)
```

```
    p_weights.append(weights)
    returns = np.dot(weights, ind_er)
    p_ret.append(returns)
    var = cov_matrix.mul(weights, axis=0).mul(weights, axis=1).sum().sum()
    sd = np.sqrt(var)
    ann_sd = sd*np.sqrt(252)
    p_vol.append(ann_sd)
```

[19]:
```
data = {'Returns': p_ret, 'Volatility': p_vol}

for counter, symbol in enumerate(df.columns.tolist()):
    data[symbol+ 'weights'] = [w[counter] for w in p_weights]
```

[20]:
```
portfolios = pd.DataFrame(data) # Dataframe dos 50 mil portfólios criados
```

[21]:
```
# Plot efficient frontier
portfolios.plot.scatter(x='Volatility', y='Returns', marker='o', s=10, alpha=0.
↪3, grid=True, figsize=[5,5])
```

[21]: <AxesSubplot:xlabel='Volatility', ylabel='Returns'>

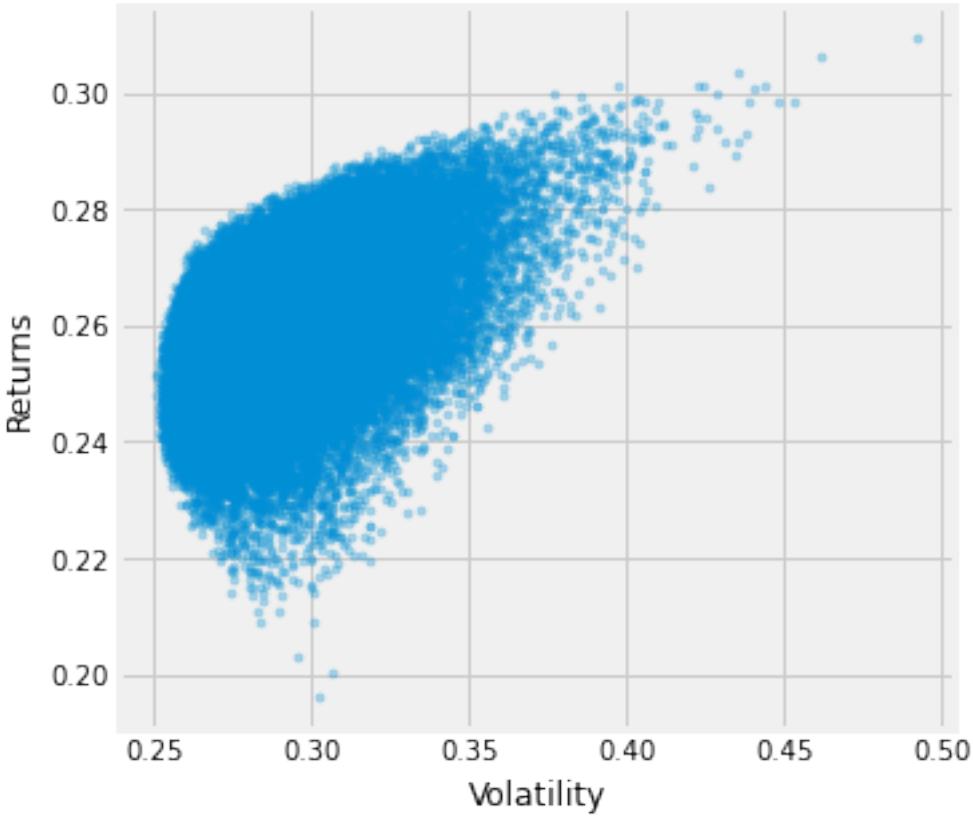

9.1 Pesos do portfólio mais eficiente com menor volatilidade

[22]:
```
min_vol_port = portfolios.iloc[portfolios['Volatility'].idxmin()]
# idxmin() gives us the minimum value in the column specified.
min_vol_port = pd.DataFrame(min_vol_port)
min_vol_port
```

[22]:

	9082
Returns	0.247776
Volatility	0.250985
ENGI11.SAweights	0.316274
EQTL3.SAweights	0.404900
ITSA4.SAweights	0.255545
LREN3.SAweights	0.021834
PETR4.SAweights	0.001447

9.2 Pesos do portfólio com o maior Sharpe Ratio

[38]:
```
rf = 0.0275 # risk factor
optimal_risky_port = portfolios.iloc[((portfolios['Returns']-rf)/
↪portfolios['Volatility']).idxmax()]
optimal_risky_port = pd.DataFrame(optimal_risky_port)
optimal_risky_port
```

[38]:

	28974
Returns	0.272244
Volatility	0.260987
ENGI11.SAweights	0.253444
EQTL3.SAweights	0.626193
ITSA4.SAweights	0.014353
LREN3.SAweights	0.044566
PETR4.SAweights	0.061444

9.3 Pesos do portfólio com maior retorno

[43]:
```
max_ret_port = portfolios.iloc[portfolios['Returns'].idxmax()]
max_ret_port = pd.DataFrame(max_ret_port)
max_ret_port
```

[43]:

	1181
Returns	0.309471
Volatility	0.492294
ENGI11.SAweights	0.060285
EQTL3.SAweights	0.001548
ITSA4.SAweights	0.040974
LREN3.SAweights	0.024111

PETR4.SAweights 0.873082